

计算机科学与探索
Journal of Frontiers of Computer Science and Technology
ISSN 1673-9418,CN 11-5602/TP

《计算机科学与探索》网络首发论文

题目：面向不对称因果关系消除的因果结构学习算法
作者：郭贤杰，周浩，俞奎
网络首发日期：2026-08-19
引用格式：郭贤杰，周浩，俞奎. 面向不对称因果关系消除的因果结构学习算法[J/OL]. 计算机科学与探索. https://link.cnki.net/urlid/11.5602.tp.20260819.1012.002



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2026-08-19 15:38:01　网络首发地址：https://link.cnki.net/urlid/11.5602.tp.20260819.1012.002

计算机科学与探索
Journal of Frontiers of Computer Science and Technology　doi: 10.3778/j.issn.1673-9418.2605099

面向不对称因果关系消除的因果结构学习算法

郭贤杰[1,2]，周浩[1,2]，俞奎[3+]

1. 南京邮电大学 计算机学院、软件学院、网络空间安全学院，南京 210023
2. 南京邮电大学通达学院，江苏 扬州 225127
3. 合肥工业大学 计算机与信息学院，合肥 230601
+ 通信作者 E-mail: yukui@hfut.edu.cn

摘要：因果结构学习旨在从可观测数据中揭示变量间的因果关系。局部到全局策略因兼具较高的学习精度与良好的高维可扩展性而被广泛采用，但其在利用局部因果结构拼接全局结构时普遍受到不对称因果关系的困扰，严重制约了学习性能。针对这一瓶颈，提出一种基于不对称因果关系消除的因果结构学习算法 ECSL（elimination of asymmetric causal relationships for causal structure learning）。ECSL 首先在原始数据上学习各变量的因果邻居并识别不对称因果关系；然后利用自助法重采样生成多批次子数据集，并以因果邻居对称比率为核心设计子数据集质量评估准则，迭代式地筛选出质量最优的一批子数据集；进而在最优批次上以加权打分策略消除不对称因果关系并重构全局骨架；最后通过加权聚合各子数据集上定向得到的因果结构获得最终的全局因果结构。在 12 个基准贝叶斯网络数据集和 Sachs 真实数据集上，与当前主流的全局因果结构学习算法相比，ECSL 在 F1 分数和结构汉明距离两项指标上均取得最优或有竞争力的结果；消融实验进一步验证了所提出的子数据集质量评估策略和迭代重采样策略中各关键组件的有效性。

关键词：局部因果结构；全局因果结构；局部到全局因果结构学习；不对称因果关系；重采样

文献标志码：A　　**中图分类号**：TP181

Causal Structure Learning Algorithms for Asymmetric Causal Relationship Elimination

GUO Xianjie[1,2], ZHOU Hao[1,2], YU Kui[3+]

1. School of Computer Science, Nanjing University of Posts and Telecommunications, Nanjing 210023, China
2. Tongda College of Nanjing University of Posts and Telecommunications, Yangzhou, Jiangsu 225127, China
3. School of Computer Science and Information Engineering, Hefei University of Technology, Hefei 230601, China

Abstract: Causal structure learning aims to uncover causal relationships among variables from observational data. The local-to-global strategy has been widely adopted for its high accuracy and good scalability to high-dimensional data, yet it commonly suffers from asymmetric causal relationships when assembling the global structure from local ones, which severely degrades its performance. To address this bottleneck, this paper proposes ECSL (elimination of asymmetric causal relationships for causal structure learning). ECSL first learns the causal neighbors of each variable on the original data and

基金项目：江苏省高等学校基础科学(自然科学)研究项目(25KJB520036、25KJB520040)；江苏省基础研究计划(BK20250656)；国家自然科学基金项目（62506174、62376087）。

This work was supported by the Basic Science (Natural Science) Foundation of the Jiangsu Higher Education Institutions of China (25KJB520036, 25KJB520040), the Basic Research Program of Jiangsu (BK20250656), and the National Natural Science Foundation of China (62506174, 62376087).

identifies the asymmetric causal relationships; it then generates multiple batches of sub-datasets via bootstrap resampling, and designs a sub-dataset quality assessment criterion centered on the symmetry ratio of causal neighbors to iteratively select the highest-quality batch; next, a weighted scoring strategy is applied on the optimal batch to eliminate the asymmetric relationships and reconstruct the global skeleton; finally, the causal structures oriented on each sub-dataset are aggregated through a weighted aggregation strategy to obtain the final global causal structure. On 12 benchmark Bayesian network datasets and the real-world Sachs dataset, compared with existing mainstream global causal structure learning algorithms, ECSL achieves the best or highly competitive results on both F1 score and structural Hamming distance; ablation experiments further verify the effectiveness of each key component in the proposed sub-dataset quality assessment and iterative resampling strategies.

Key words: local causal structure; global causal structure; local-to-global causal structure learning; asymmetric causal relationships; resampling

因果结构学习（causal structure learning）旨在通过可观测数据来揭示事件或变量之间的因果关系[1-3]，以支持事件推理和分析[4]。例如，在复杂生产过程中，对因果关系的深入理解有助于准确分析故障的根本原因，从而提高生产效率和产品质量。近年来，这一领域的方法引起了学术界和工业界的广泛关注，常见的应用场景包括但不限于大数据挖掘[5]、情感分析[6]、生物学[7]，以及医学诊断[8]等。通常情况下，复杂系统中变量之间的因果关系通过基于有向无环图（directed acyclic graph，DAG）的因果图模型表示[9-10]。在 DAG 中，一条有向边$X_i \to X_j$被解释为直接原因（X_i）和直接结果（X_j）的关系[11-12]。尽管随机控制实验是挖掘变量间因果关系的最有效方法，但实验成本高、技术难度大等因素限制了其应用。因此，从可观测数据中学习因果结构（即 DAG）的过程已经成为推断变量之间因果关系的主要方法，备受研究者青睐。

现有的因果结构学习方法[13-14]根据学习规模的策略不同主要分为全局方法和局部到全局方法两类。其中，全局方法包括 PC 算法[15]及其变种算法[16-18]、GES 算法[19]及其变种算法[20-21]、NOTEARS 算法[22]及其衍生算法[23-25]等，这些方法分别利用条件独立性测试、搜索评分策略和连续优化策略，直接一次性学习数据集中所有变量构成的整个因果结构。然而，全局因果结构学习通常是一个 NP 难问题[26]，或者需要利用复杂的优化技术[22]和复杂的神经网络模型[23]，导致其可扩展性显著降低。特别是当数据集的维度较高时，大多数现有的全局因果结构学习算法会遇到计算复杂度过大的问题。此外，如果这类方法在其前期的因果边学习过程中产生错误（例如，缺失因果边、额外添加因果边或因果边方向逆向），这些错误将在后续的结构学习过程中无法进行进一步的修正，并在后续学习过程中引发级联错误，导致最终学习的因果结构的准确性不尽如人意。

为了解决全局因果结构学习算法在可扩展性和准确性方面的挑战，局部到全局的因果结构学习方法应运而生。这包括如 GSBN 算法[27]、SLL+C/G 算法[28]、GGSL 算法[29]和 F2SL-c/s 算法[30]等。近年来，针对局部到全局框架中局部骨架（即因果邻居）学习精度不足的问题，研究者展开了进一步探索：Guo 等人[31]提出了一种自适应骨架构建方法，通过自适应地调整条件独立性检验的条件集来获得更准确的 DAG 骨架；随后，Guo 等人[32]又提出了一种渐进式骨架学习方法，以由易到难、逐步精化的策略提升局部到全局因果结构学习的可靠性。这些方法一般遵循三个步骤：1) 独立地确定每个变量的因果邻居（也称为局部骨架）[33]；2) 根据变量是否互为因果邻居的关系来构建全局骨架；3) 利用 Meek 规则[34]或基于评分的搜索策略[35]对全局骨架中的无向边进行定向。这类方法通过将学习过程从局部扩展到全局，能够更有效地处理大规模数据集，同时提高学习结果的准确性。

进一步比较可以发现，全局方法与局部到全局方法在建模范式上存在本质差异，各自的瓶颈也不同：

全局方法（如基于评分的 GES、基于约束的 PC 及基于连续优化的 NOTEARS 等）一次性在全体变量上搜索或优化整个结构，其优点是能够利用全局信息，但求解空间随变量数呈超指数增长，在高维数据上计算代价高昂，且早期学到的错误边会沿依赖路径不断放大，引发级联错误；局部到全局方法（如 GSBN、SLL+C/G、GGSL、F2SL-c/s 等）先以各变量为中心独立学习局部骨架再拼接为全局结构，显著降低了单次搜索规模、缓解了级联错误，但其精度高度依赖局部骨架的可靠性——当数据存在噪声或样本不足时，不同变量给出的局部结果彼此不一致，表现为大量不对称因果关系，成为制约该类方法精度的关键且长期被忽视的瓶颈，这正是本文着力解决的问题。

尽管现有的局部到全局因果结构学习方法在效率和准确性方面取得了显著进展，但由于不可避免的数据质量问题（例如噪声和小样本），它们的性能仍然存在一定的局限性。具体而言，数据质量问题可能导致在利用所有变量的因果邻居构建全局骨架时出现不对称的因果关系。例如，当以变量X_i为目标学习其因果邻居时，发现变量X_j属于其因果邻居；然而，当以变量X_j为目标学习其因果邻居时，却发现变量X_i并不属于其因果邻居。事实上，任意两个变量之间的因果关系一定是对称的，即要么互为彼此的因果邻居，要么互不为彼此的因果邻居。这种不对称的情况使得在构建全局骨架时难以判断变量X_i和变量X_j之间是否存在一条因果边。同时，这也意味着变量X_i和变量X_j中至少有一个的因果邻居学习错误。在实际场景中，这种情况是普遍存在的，并且对全局因果骨架的构建产生了严重影响。

为了说明现有的局部到全局因果结构学习算法在学习不对称因果关系方面的普遍性，采用了五个经典的因果邻居学习算法，分别是 HITON-PC 算法[36]、MBtoPC 算法[37]、MMPC 算法[38]、PC-simple 算法[39]和 FCBF-PC 算法[30]，并在三个常用的基准贝叶斯网络（Alarm、Child 和 Insurance）上进行了实验。具体而言，首先利用 Alarm、Child 和 Insurance 生成了三批数据，每一批数据包含 200、300、400、500、1,000、2,000、3,000、4,000 和 5,000 个样本。然后，在这三批数据集上运行了上述提到的五个经典的因果邻居学习算法。最后，记录了所有算法在不同基准贝叶斯网络数据集上产生的不对称因果关系的平均比例大小，并将实验结果记录在图 1 中。从实验结果中可以观察到，在所有数据集上，不同因果邻居学习算法产生的不对称因果关系比例大小的平均值在 12%到 42%之间。这些不对称因果关系的出现意味着有很多变量的因果邻居学习错误，导致构建的全局骨架不准确，最终影响所学习因果结构的精确性。这是目前限制局部到全局因果结构学习算法学习精度的重要瓶颈，鲜有研究工作关注并设计有效方法解决这个问题。

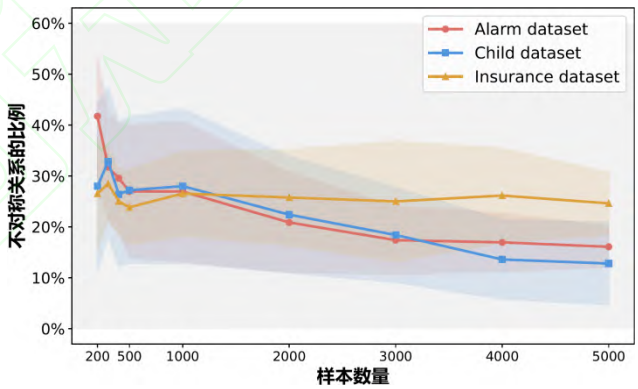


图 1　不对称因果关系的比例随样本量的减少而显著增加

Fig.1　The proportion of asymmetric causal relationships increases significantly as the sample size decreases

为了解决上述问题，提出了一种面向不对称因果关系消除的因果结构学习算法，命名为 ECSL（elimination of asymmetric causal relationships for causal structure learning）。该算法通过不断纠正每个变量的因果邻居学习准确性，以消除不对称因果关系，从而获得更精准的全局骨架，提升因果结构学习的性能。具体而言，ECSL 首先在原始数据集上学习每个变量的因果邻居并记录下所有产生的不对称因果关系。接着，基于原始数据集，ECSL 运用数据重采样技术生成多批次子数据集，并在每批子数据集上重新学习那些具有不对称因果关系的变量的因果邻居。在生成的多批次子数据集中，ECSL 设计了一种评分策略，旨在挑选出能够最大程度降低不对称因果关系比例的子数

据集作为最佳的一批子数据集。随后，ECSL 基于这批最佳子数据集以及在其上进行的因果邻居学习结果，设计了一种基于打分的不对称因果关系纠正策略。该策略旨在重构全局骨架以获得最优的全局骨架。最后，在质量最佳的一批子数据集中，ECSL 针对每个子数据集对最优的全局骨架进行多次定向生成多个因果结构，并通过加权聚合策略得出最终的因果结构。在 12 个常用的基准贝叶斯网络数据集和一个真实世界数据集上对 ECSL 进行了充分验证，实验结果表明，该算法在不同类型的数据集上均取得了显著的性能提升。

本文的组织结构如下：第 1 节介绍因果结构学习的相关工作；第 2 节给出本文所需的符号定义和技术支撑；第 3 节详细介绍本文提出的基于不对称因果关系消除的因果结构学习算法；第 4 节提供实验设置和对实验结果的深入分析；最后，第 5 节总结全文并展望未来工作。

1 相关工作

近年来，许多因果结构学习算法已经被提出。根据学习规模的策略不同，因果结构学习的方法主要分为全局方法[15,19,22]和局部到全局的方法[27,29-30]两类。

1.1 全局因果结构学习

全局因果结构学习方法将因果结构学习问题形式化为一个组合优化问题[19]或连续优化问题[22]。在组合优化问题中，现有的全局因果结构学习方法可以细分为两类：基于评分的方法和基于约束的方法[13]。基于评分的算法，如 GES 算法[19]及其变体算法[20-21]，通常使用评分函数来衡量不同因果结构对数据的拟合程度，然后使用搜索过程找到最佳因果结构[40]。相比之下，基于约束的方法，如 PC 算法[15]及其变体算法[16-18]，采用条件独立性测试首先评估变量之间是否存在边以学习全局骨架（无向图），然后使用 Meek 规则[34]定向边。

为了避免组合约束，近期，Zheng 等人[22]将全局因果结构学习问题转化为一个连续优化问题并提出了 NOTEARS 算法，该算法将无环约束形式化为一个平滑项并使用基于梯度的数值方法解决问题。NOTEARS 算法专门针对变量之间为线性关系的因果结构数据而设计，并已借助神经网络模型扩展到非线性情形[23-25]。例如，DAG-GNN[23]使用变分自编码器重构数据，并使用证据下界（evidence lower bound，ELBO）损失作为其损失函数。文献[24]的作者研究了稀疏性和 DAG 约束在一般线性高斯情况和其他特定情况下的渐近作用，并开发了一种基于似然的因果结构学习方法，被命名为 GOLEM 算法。该方法的新颖之处在于采用连续无约束优化。与 GOLEM 算法相比，MCSL-MLP 算法[25]在重新构建的结构方程模型（structural equation model，SEM）基础上，利用基于梯度的优化进行高效训练。通过引入关于无环性的平滑特性和 Gumbel-Softmax 方法，该算法能够近似二值邻接矩阵，为连续优化的因果结构学习提供了一种创新思路。

近年来，将机器学习与可解释性技术引入因果发现成为新的研究趋势。例如，Renero 等人[41]提出的 ReX 算法先为每个变量训练深度前馈网络和梯度提升树等回归模型，再借助 Shapley 值度量各特征对目标变量的条件依赖强度以筛选候选父节点，随后结合加性噪声模型（additive noise model，ANM）确定边的方向并消除环路，为因果结构学习提供了一种基于可解释性的新思路。

然而，这些全局因果结构学习算法试图一次性学习由所有变量构成的整个因果结构，在面对高维数据（含有大量的变量）时可能面临计算量过大的问题。此外，如果这些全局因果结构学习方法在早期学习阶段学到了错误的边，那么围绕这些错误边的学习和定向将受到严重影响，导致更多的错误。

1.2 局部到全局的因果结构学习

为了提高因果结构学习的效率和效果，研究人员设计出了从局部到全局的因果结构学习方法。这些方法首先独立地学习每个变量的因果邻居（也叫局部骨架），而不是一次性学习全局因果结构。在过去的二十

年中，许多局部到全局的因果结构学习方法被提出。例如，GSBN 算法[27]首先利用 GSMB 算法[27]学习每个变量的因果邻居，然后构建全局骨架，最后使用 Meek 规则[34]定向全局骨架中的无向边。与 GSBN 算法相比，MMHC 算法[42]使用 MMPC 算法[38]学习每个变量的因果邻居，并使用搜索评分策略定向全局骨架中的无向边。SLL+C/G 算法[28]首先使用基于评分的局部因果结构学习算法（称为 SLL 算法[28]）找到每个变量的因果邻居，然后通过组合所有局部骨架构建全局骨架，最后 SLL+C 算法使用条件独立性测试结合 Meek 规则在全局骨架中定向边，而 SLL+G 算法则采用搜索评分策略定向边。与前面的方法不同的是，GGSL 算法[29]不是预先找到每个变量的因果邻居，而是首先随机选择一个变量并学习该变量周围的局部因果结构，然后逐渐扩展已学习的结构，直到整个因果结构被学习。最近，Yu 等人[30]指出，现有的局部到全局因果结构学习方法所采用的因果邻居学习方法通常需要较高的计算成本，尤其是在大型网络中。为了进一步提高局部到全局因果结构学习算法的效率，他们将一种高效的特征选择方法与因果结构学习相结合，提出了两种高效的从局部到全局的因果结构学习算法，即 F2SL-c 算法和 F2SL-s 算法[30]，它们分别采用不同的定向策略（基于约束的方法或基于评分的方法）。

此外，Dong 等人[43]提出了一种面向大规模因果结构学习的分而治之算法 DCILP：在“分”阶段，先估计每个变量的马尔可夫毯，将原始问题分解为若干规模更小、样本-变量比更有利的子问题并行求解；在“治”阶段，创新性地将局部因果子图的融合与协调问题形式化为整数线性规划（integer linear programming，ILP）问题，并交由高效的 ILP 求解器处理，从而在保持学习精度的同时显著提升了可扩展性。DCILP 同样遵循“局部到全局”的思想，但其马尔可夫毯估计基于高斯线性结构方程模型假设。

然而，在许多现实环境中，由于数据质量问题（例如噪声和小样本），现有的局部到全局因果结构学习方法可能会产生许多不对称的因果关系。这些不对称因果关系的出现是目前限制局部到全局因果结构学习算法学习精度的重要瓶颈，鲜有研究关注并设计有效方法来解决这一问题。在本文中，基于数据重采样技术和集成学习思想，设计了一种有效的不对称因果关系纠正策略，从而缓解了数据质量问题对局部到全局因果结构学习精度的影响。

2 预备知识

在本文中，用$\boldsymbol{X}=\{X_1,X_2,\ldots,X_m\}$来表示一组随机变量，并使用因果图来表示$\boldsymbol{X}$上的全局因果结构。最为常用的图形化表达方式是因果有向无环图（DAG）[44]，记为$\mathcal{G}=(\boldsymbol{X},\boldsymbol{E})$。在这里，$\boldsymbol{E}\subseteq\boldsymbol{X}\times\boldsymbol{X}$代表一个有向边集合，每条有向边表示$\boldsymbol{X}$中一对变量间的直接因果关系。此外，$\mathcal{G}$不包含任何有向环，确保了其为无环图。具体来说，因果 DAG 中的一条有向边$X_i\to X_j$表示X_i是X_j的直接原因，而X_j是X_i的直接结果，并且称X_i和X_j互为彼此的因果邻居。$\boldsymbol{X}$上的因果 DAG 所对应的全局骨架（记为$\mathcal{S}$）被表示为一个包含$\boldsymbol{X}$和$\boldsymbol{X}$中变量之间的无向边的无向图。当使用因果 DAG 来表示因果结构时，因果结构学习旨在从可观测数据中学习一组变量$\boldsymbol{X}$上的因果 DAG，其中边表示变量之间潜在的因果关系。也就是说，对于任意一对变量$X_i,X_j\in\boldsymbol{X}$，仅当因果结构学习过程确定X_i是X_j的潜在直接原因时，才会在因果 DAG 中包含边$X_i\to X_j$[44]。可是，正如图 1 所示，现有的局部到全局的因果结构学习方法在利用所有变量的因果邻居（也叫局部骨架）拼接全局骨架时，可能会遇到许多不对称的因果关系，其定义如下。

定义 1（不对称因果关系） 当使用因果邻居学习算法去学习两个变量X_i和X_j（$X_i,X_j\in\boldsymbol{X}$）的因果邻居时，如果X_i的因果邻居里面包含了X_j但是X_j的因果邻居不包含X_i（反之亦然），则称X_i和X_j之间存在不对称的因果关系。

两个变量的条件独立/依赖性定义如下。

定义 2（条件独立性） 两个不同的变量X_i和X_j

$(X_i, X_j \in \boldsymbol{X})$ 被认为在给定变量子集$\boldsymbol{Z} \subseteq \boldsymbol{X} \setminus \{X_i, X_j\}$下是条件独立的当且仅当$P(X_i, X_j|\boldsymbol{Z}) = P(X_i|\boldsymbol{Z})P(X_j|\boldsymbol{Z})$成立，否则$X_i$和$X_j$被认为在变量子集$\boldsymbol{Z}$下条件依赖。

命题 1[44] 在一个因果 DAG 中，如果变量X_i和X_j（$X_i, X_j \in \boldsymbol{X}$）之间存在一条直接边相连，那么对于任意变量子集$\boldsymbol{Z} \subseteq \boldsymbol{X} \setminus \{X_i, X_j\}$，$X_i$和$X_j$在给定$\boldsymbol{Z}$的条件下都是条件依赖。

命题 1 表明，如果X_i是X_j的因果邻居，则在由其他变量所组成的任何子集的条件下，X_i和X_j总是条件依赖。命题 1 是基于约束的因果邻居学习算法学习一个目标变量的因果邻居的基础原理。

命题 2 在一个因果 DAG 中，对于任意两个变量X_i和X_j $(X_i, X_j \in \boldsymbol{X})$，$X_i$是$X_j$的因果邻居，当且仅当$X_j$是$X_i$的因果邻居。

命题 2 可由因果邻居的定义直接得到：X_i与X_j互为因果邻居，等价于二者在因果 DAG 中由一条边直接相连，而这条边是否存在与从哪一端考察它无关。命题 2 意味着真实因果结构中的因果邻居关系必然对称，因此定义 1 所刻画的不对称因果关系不可能出现在真实因果结构中，它一旦出现，就意味着X_i和X_j中至少有一个变量的因果邻居被学错。这为 3.2 节以因果邻居对称比率度量子数据集质量提供了依据。

本文采用了自助法[45]以应对原始数据集存在的质量问题。鉴于自助法在每轮重采样时所引入的随机性，为了准确评估每次重采样得到的数据集质量，本文提出了以下假设 1。

关于重采样数据能够代表原始数据分布的依据，说明如下：自助法是一种非参数重采样技术，它从原始样本中有放回地抽样，其抽样分布即原始数据的经验分布。根据 Glivenko–Cantelli 定理，当样本量足够时经验分布以概率 1 一致收敛于真实分布，因此自助样本在统计意义上能够近似代表原始数据所蕴含的分布信息；同时，每个自助子数据集期望包含约 63.2% 的不重复原始样本，既保留了主体分布特征，又通过样本组合的随机扰动带来多样性。需要强调的是，ECSL 并不依赖单个自助子数据集来做判定，而是通过“多子数据集集成+质量评估筛选+加权聚合”的机制，在降低单次重采样随机性的同时，自动偏向那些更能代表真实因果结构的高质量子数据集，从而进一步保证了重采样结果的代表性与稳健性。

假设 1 令$Q(D_{l_1})$和$Q(D_{l_2})$分别表示数据集D_{l_1}和D_{l_2}的质量，同时令$Acc(\mathcal{S}_{l_1})$和$Acc(\mathcal{S}_{l_2})$相应地表示在相同因果邻居学习算法下，从数据集D_{l_1}和D_{l_2}中学到的因果骨架的准确度。若存在不等式关系$Acc(\mathcal{S}_{l_1}) > Acc(\mathcal{S}_{l_2})$，那么可以推断出$Q(D_{l_1}) > Q(D_{l_2})$。

此外，用D表示具有m个变量和n个样本的单个数据集，并使用$\mathcal{D}$表示含有L个相同维度和样本数量的一批数据集，即$\mathcal{D} = \{D_l\}_{l\in\{1,2,\ldots,L\}} = \{D_1, D_2, \ldots, D_L\}$。

3 ECSL 算法

3.1 整体框架

本文提出了一种基于不对称因果关系消除的因果结构学习算法，命名为 ECSL。该算法包含如图 2 所示的三个学习步骤。

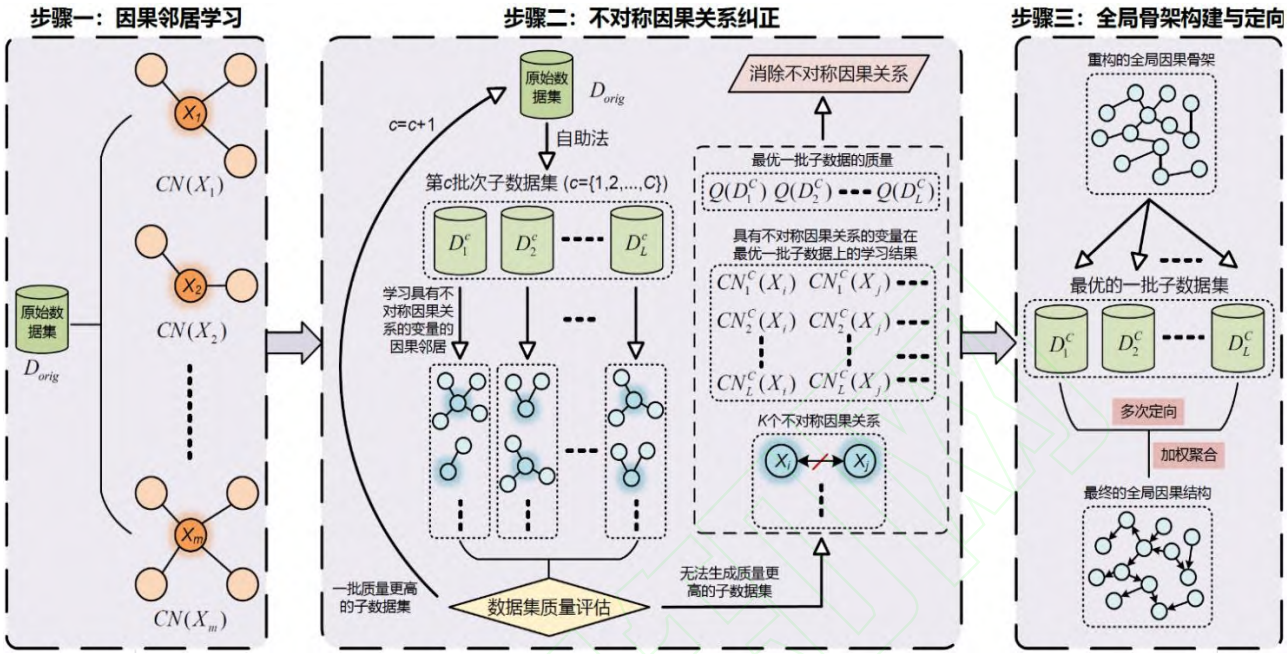


图 2　ECSL 算法的总体框架

Fig.2　Overall framework of the proposed ECSL algorithm

步骤 1：使用因果邻居学习算法在原始数据集上独立地学习出每个变量的因果邻居集，并识别出变量间所有不对称的因果关系。该步骤可以使用多种常用因果邻居学习算法，例如 HITON-PC 算法[36]、MBtoPC 算法[37]、MMPC 算法[38]、PC-simple 算法[39]和 FCBF-PC 算法[30]。

步骤 2：首先利用自助法[45]对原始数据集进行重采样，生成多批次子数据集（每批次子数据集中包含多个子数据集）。接着，在每批次子数据集中的每个子数据集上，对具有不对称因果关系的变量的因果邻居进行重新学习。随后，根据新的学习结果，ECSL 设计了一种数据集质量评估准则，以选择质量最优的一批次子数据集。最后，基于在最优的一批次子数据集上学到的具有不对称因果关系的变量的因果邻居，ECSL 设计了一种新颖的打分策略，以消除所有不对称因果关系。

步骤 3：使用所有变量之间对称的因果关系来构建全局骨架。然后，采用爬山搜索结合贝叶斯狄利克雷等价均匀（Bayesian Dirichlet equivalent uniform，BDeu）评分，将该骨架放入最优的一批次子数据集的每个子数据集上进行定向，得到多个全局因果结构。最后，ECSL 设计了一种加权聚合策略，将多个因果结构聚合成一个精准的全局因果结构。

本文的主要贡献集中在步骤 2 和步骤 3，因此，3.2 节和 3.3 节将分别详细描述这两个步骤的具体细节。

为更清晰地展示 ECSL 的具体实现，下面结合图 2 的框架给出其完整流程（算法 1）。

算法 1　ECSL
输入：原始数据集$\boldsymbol{D_{orig}}$；因果邻居学习算法 A；每批子数据集个数$\boldsymbol{L}$；连续未提升阈值$\boldsymbol{T_{stop}}$。
输出：全局因果结构（邻接矩阵）$\boldsymbol{\mathcal{G}^*}$。
1: 在$\boldsymbol{D_{orig}}$上用 A 学习每个变量的因果邻居$\{\boldsymbol{CN(X_i)}\}_{i\in\{1,2,\ldots,m\}}$，并据定义 1 识别全部$\boldsymbol{K}$个不对称因果关系；　// 步骤 1
2: 令批次索引$\boldsymbol{c\leftarrow 1}$，最优质量$\boldsymbol{Q^*\leftarrow -\infty}$，未提升计数$\boldsymbol{e\leftarrow 0}$；
3: repeat　// 步骤 2：迭代重采样并选择最优批次
4:　用自助法从$\boldsymbol{D_{orig}}$重采样生成第$\boldsymbol{c}$批含$\boldsymbol{L}$个子数据集的集合$\boldsymbol{\mathcal{D}^c=\{D_l^c\}_{l\in\{1,2,\ldots,L\}}=\{D_1^c,D_2^c,\ldots,D_L^c\}}$；
5:　for 每个子数据集$\boldsymbol{D_l^c}$ do 在$\boldsymbol{D_l^c}$上用 A 重新学习$\boldsymbol{K}$个不对称关系中各变量的因果邻居；

6: 由式 (4) 计算各$\boldsymbol{D_l^c}$的质量$\boldsymbol{Q}(\boldsymbol{D_l^c})$，再由式 (7) 计算该批平均质量$\boldsymbol{Q}(\boldsymbol{\mathcal{D}^c})$；
7: if $\boldsymbol{Q}(\boldsymbol{\mathcal{D}^c}) > \boldsymbol{Q}^*$ then $\boldsymbol{Q}^* \leftarrow \boldsymbol{Q}(\boldsymbol{\mathcal{D}^c})$，$\boldsymbol{\mathcal{D}^*} \leftarrow \boldsymbol{\mathcal{D}^c}$，$\boldsymbol{e} \leftarrow \boldsymbol{0}$；else $\boldsymbol{e} \leftarrow \boldsymbol{e} + \boldsymbol{1}$；
8: $\boldsymbol{c} \leftarrow \boldsymbol{c} + \boldsymbol{1}$；
9: until 连续$\boldsymbol{T_{stop}}$次出现$\boldsymbol{Q}(\boldsymbol{\mathcal{D}^c}) \le \boldsymbol{Q}^*$(即$\boldsymbol{e} \ge \boldsymbol{T_{stop}}$)；
10: 基于最优批次$\boldsymbol{\mathcal{D}^*}$，由式 (6) 的加权打分策略依次纠正$\boldsymbol{K}$个不对称因果关系；
11: 结合对称关系与纠正结果，由式 (8) 构建全局骨架$\boldsymbol{\mathcal{S}}$； // 步骤 3
12: for 每个$\boldsymbol{D_l^c} \in \boldsymbol{\mathcal{D}^*}$do 用爬山搜索结合 BDeu 评分在$\boldsymbol{D_l^c}$上定向$\boldsymbol{\mathcal{S}}$，得到结构$\boldsymbol{\mathcal{G}_l^c}$；
13: 由式 (9) 对$\{\boldsymbol{\mathcal{G}_l^c}\}_{l\in\{1,2,\ldots,L\}}$进行加权聚合，再由式 (10) 比较得到最终全局因果结构$\boldsymbol{\mathcal{G}^*}$；
14: return $\boldsymbol{\mathcal{G}^*}$。

3.2 不对称因果关系纠正

步骤 1 通过在原始数据集D_{orig}上运行现有的因果邻居学习算法已经得到了变量集$\boldsymbol{X} = \{X_1, X_2, \ldots, X_m\}$中每个变量的因果邻居 (causal neighbor，CN)，即$\{CN(X_i)\}_{i\in\{1,2,\ldots,m\}} = \{CN(X_1), CN(X_2), \ldots, CN(X_m)\}$。对于$\boldsymbol{X}$中任意两个变量$X_i$和$X_j$，他们之间的因果关系一定是如下四种情形之一：(1) $X_i \in CN(X_j)$且$X_j \in CN(X_i)$；(2)$X_i \notin CN(X_j)$且$X_j \notin CN(X_i)$；(3)$X_i \in CN(X_j)$但$X_j \notin CN(X_i)$；(4) $X_j \in CN(X_i)$但$X_i \notin CN(X_j)$。其中 (1) 和 (2)表明X_i和X_j之间因果关系是对称的，而(3)和 (4)表明X_i和X_j之间因果关系是不对称的 (详见定义 1)。当两个变量之间因果关系是对称的时候，有很大的把握能正确地判断出两个变量之间是否存在一条无向边相连。因此，本文提出了以下假设 2。

假设 2 给定一个因果邻居学习算法，用于学习两个变量X_i和X_j (其中$X_i, X_j \in \boldsymbol{X}$) 的因果邻居，如果学到的因果邻居结果表明$X_i$和$X_j$之间的因果关系是对称的，那么可以通过以下两个准则正确判定X_i和X_j之间是否存在一条因果边相连：

(1) 如果$X_j \in CN(X_i)$且$X_i \in CN(X_j)$成立，那么X_i和X_j之间存在一条因果边相连。

(2) 如果$X_j \notin CN(X_i)$且$X_i \notin CN(X_j)$成立，那么X_i和X_j之间不存在一条因果边相连。

当两个变量之间因果关系是不对称的时候，基于数据重采样技术和集成学习思想，设计了一种新颖的不对称因果关系纠正策略。该策略利用自助法[45]对原始数据集D_{orig}进行重采样生成一批含有L个子数据集的数据集集合。由于步骤 2 需要通过循环重采样的方式寻找质量最优的一批子数据集，所以需要使用自助法生成多批次子数据集。为了区分不同批次的子数据集集合，使用$\mathcal{D}^c = \{D_l^c\}_{l\in\{1,2,\ldots,L\}} = \{D_1^c, D_2^c, \ldots, D_L^c\}$表示第$c$批子数据集集合(不妨设总共需要$C$批次子数据集，即$c = 1,2,\ldots,C$)，并用$CN_l^c(X_i)$表示变量$X_i$在子数据集$D_l^c$上学到的因果邻居。

起初，在第 1 批子数据集$\{D_l^1\}_{l\in\{1,2,\ldots,L\}}$中的每个子数据集上，重新学习了具有不对称因果关系的变量的因果邻居。例如，假设在D_{orig}上学到的关于X_i和X_j之间的因果关系是不对称的，那么会得到关于X_i和X_j的新的因果邻居学习结果$\{CN_l^1(X_i)\}_{l\in\{1,2,\ldots,L\}}$和$\{CN_l^1(X_j)\}_{l\in\{1,2,\ldots,L\}}$。基于集成学习的思想，可以通过考察$X_i$和$X_j$在第 1 批次的每个子数据集上学到的新的因果关系来纠正X_i和X_j之间的不对称因果关系，以判断它们之间是否存在一条无向边。

具体而言，使用$score(X_i, X_j, c, l)$来记录在第c批子数据集中的第 1 个子数据集上学到的关于X_i的因果邻居是否包含X_j。如果$X_j \in CN_l^c(X_i)$，则$score(X_i, X_j, c, l) = 1$；否则，$score(X_i, X_j, c, l) = -1$。类似地，如果$X_i \in CN_l^c(X_j)$，则$score(X_j, X_i, c, l) = 1$；否则，$score(X_j, X_i, c, l) = -1$。随后，使用$Score(X_j, X_i, c)$来记录$X_i$和$X_j$之间的不对称因果关系在第$c$批次子数据集上的集成总得分。上述的$score(X_i, X_j, c, l)$和$Score(X_j, X_i, c)$可以形式化地表示为：

$$score(X_i, X_j, c, l) = \begin{cases} 1, & X_j \in CN_l^c(X_i), \\ -1, & X_j \notin CN_l^c(X_i). \end{cases} \quad (1)$$

$$Score(X_i, X_j, c) = Score(X_j, X_i, c) = \sum_{l=1}^{L}(score(X_i, X_j, c, l) + score(X_j, X_i, c, l)). \quad (2)$$

于是，X_i和X_j之间的不对称因果关系在第 1 批子数据集上的集成总得分为$Score(X_i, X_j, 1)$。基于集成学习的思想，若$Score(X_i, X_j, 1) > 0$，则判定X_i和X_j之间存在一条无向边；反之，认为它们之间不存在无向边。

此处以 0 作为判定阈值，具有明确的含义而非人为设定的超参数：集成总得分是各高质量子数据集“支持相连（+权重）”与“支持不相连（−权重）”两类证据的加权求和，因此“得分大于 0”等价于按子数据集质量加权后的多数投票结果偏向“存在无向边”，“小于等于 0”则偏向“不存在无向边”。0 是这一带符号加权投票的自然中性分界，无需引入额外阈值参数，且由于权重集中于高质量子数据集，判定结果对阈值的微小扰动并不敏感。

由于自助法具有一定的随机性，仅仅利用第 1 批子数据集上的学习结果来纠正变量之间的不对称因果关系可能并非最佳选择。于是，设计了一种评估重采样子数据集质量的策略，以选择最优的一批子数据集来纠正变量之间的不对称因果关系。该策略的理论基础建立在下述定理 1 上。

定理 1 令$D_{l_1}^{c_1}$和$D_{l_2}^{c_2}$（$c_1, c_2 \in \{1,2,\dots,C\}$；$l_1, l_2 \in \{1,2,\dots,L\}$）为通过自助法重采样得到的任意两个子数据集。记$Q(D_{l_1}^{c_1})$和$Q(D_{l_2}^{c_2})$分别为这两个子数据集的质量度量。同时，$\mu_1$和$\mu_2$分别表示使用相同的因果邻居学习算法在$D_{l_1}^{c_1}$和$D_{l_2}^{c_2}$上学到的变量间因果关系的对称比率。当假设 1 和假设 2 同时成立时，对于给定的因果邻居学习算法而言，如果$\mu_1 > \mu_2$，那么$Q(D_{l_1}^{c_1}) > Q(D_{l_2}^{c_2})$。

证明 对于任意两个变量X_i和X_j（$i, j \in \{1,2,\dots,m\}$），如果X_i和X_j之间的因果关系不对称，则必然导致在构建全局骨架时，X_i和X_j中的一个变量的因果邻居被错误地识别，而另一个变量的因果邻居被正确地识别。这意味着在这种情况下，X_i和X_j之间因果关系的学习准确度在理论上为 50%；相反，如果X_i和X_j之间因果关系是对称的，并且在假设 2 成立的前提下，那么全局骨架中X_i和X_j之间的因果关系的学习精度为 100%。因此，$D_{l_1}^{c_1}$上学到的全局因果骨架的精度为

$$\frac{\frac{m*(m-1)}{2}*\mu_1 + \frac{m*(m-1)}{2}*(1-\mu_1)*0.5}{\frac{m*(m-1)}{2}} = \mu_1 + (1-\mu_1)*0.5 = 0.5 + 0.5*\mu_1. \quad (3)$$

相似地，$D_{l_2}^{c_2}$上学到的全局因果骨架的精度为$0.5 + 0.5*\mu_2$。因为$\mu_1 > \mu_2$成立，所以可以得到$(0.5 + 0.5*\mu_1) > (0.5 + 0.5*\mu_2)$，即$D_{l_1}^{c_1}$上学到的全局因果骨架的精度大于$D_{l_2}^{c_2}$上学到的全局因果骨架的精度。由于假设 1 成立，所以$Q(D_{l_1}^{c_1}) > Q(D_{l_2}^{c_2})$成立。综上所述，定理 1 证毕。

令步骤 1 期间共产生了K个不对称因果关系，且R_a^k和R_b^k分别表示第k（$k = 1,2,\dots,K$）个不对称因果关系中的两个变量。给定一个子数据集D_l^c，采用以下方式对$Q(D_l^c)$进行计算：

$$Q(D_l^c) = \frac{\sum_{k=1}^{K}\psi_l^c(k)}{K} \in [0,1], \quad (4)$$

其中$\psi_l^c(k)$表示第k个不对称因果关系在子数据集D_l^c上重新学习后是否对称，如果对称则记为 1，反之记为 0，即：

$$\psi_l^c(k) = \begin{cases} 1, \left(R_b^k \in CN_l^c(R_a^k) \wedge R_a^k \in CN_l^c(R_b^k)\right) \vee \left(R_b^k \notin CN_l^c(R_a^k) \wedge R_a^k \notin CN_l^c(R_b^k)\right), \\ 0, \left(R_b^k \in CN_l^c(R_a^k) \wedge R_a^k \notin CN_l^c(R_b^k)\right) \vee \left(R_b^k \notin CN_l^c(R_a^k) \wedge R_a^k \in CN_l^c(R_b^k)\right). \end{cases} \quad (5)$$

从公式（4）中可以看出同一批次的子数据集中不同子数据集的质量可能是不同的。因此，公式（2）应该被重新形式化为：

$$\widehat{Score}(X_i, X_j, c) = \widehat{Score}(X_j, X_i, c) = \sum_{l=1}^{L} Q(D_l^c) * \left(score(X_i, X_j, c, l) + score(X_j, X_i, c, l)\right). \quad (6)$$

此外，基于公式（4），可以计算出第c批次子数据集的平均质量$Q(\mathcal{D}^c)$为：

$$Q(\mathcal{D}^c) = \frac{\sum_{l=1}^{L} Q(D_l^c)}{L} \in [0,1]. \quad (7)$$

正如图 2 所示，为了获取最优的一批子数据集，ECSL 需要在原始数据集D_{orig}上利用自助法继续进行重采样并获得第 2 批次子数据集$\mathcal{D}^2$。紧接着，利用公式（7）去计算$\mathcal{D}^2$的平均质量并得到$Q(\mathcal{D}^2)$。如果$Q(\mathcal{D}^2) > Q(\mathcal{D}^1)$，那么 ECSL 成功获得一批次更优的子数据集，并继续循环重采样以获取最优的一批子数据集。对于任意c，如果连续多次出现$Q(\mathcal{D}^{c+1}) \le Q(\mathcal{D}^c)$，那么认为 ECSL 无法生成更优的一批子数据集并把当前批次的子数据集看作是最优的一批子数据集，即$\mathcal{D}^C$。最后，根据$\mathcal{D}^C$上关于R_a^k和R_b^k的新的因果邻居学习结果$\{CN_l^C(R_a^k), CN_l^C(R_b^k)\}_{l\in\{1,2,\dots,L\}}$以及每个子数据集的质量$\{Q(D_l^C)\}_{l\in\{1,2,\dots,L\}}$，利用公式（6）中的加权打分策略来依次纠正$K$个不对称因果关系。如果$\widehat{Score}(R_a^k, R_b^k, C) > 0$，则判定第$k$个不对称因果关系中的两个变量$R_a^k$和$R_b^k$之间存在一条无向边相连；反之，认为它们之间不存在无向边相连。

关于仅采用因果邻居对称比率作为子数据集质量度量的说明：ECSL 的目标是消除不对称因果关系，而对称比率恰好直接刻画了“重采样后由不对称转为对称的关系所占比例”，是与该目标严格对齐的度量；更重要的是，定理 1 已证明在假设 1 和假设 2 成立时，对称比率越高，则该子数据集上重构全局骨架的精度越高，二者具有单调对应关系。因此，对称比率是一种充分且任务相关的质量代理指标。相比之下，噪声水平、样本代表性等通用数据质量指标只是间接因素，与骨架精度之间不一定存在单调关系，且难以在无真值的情况下直接估计。

关于加权打分中权重与不对称关系严重程度、以及权重与最终结构准确性之间的关联机制：在式（4）—（7）中，子数据集（及批次）的权重正比于其对称比率，即该子数据集上被成功纠正为对称的不对称关系的比例。当一个子数据集能把更多的不对称关系纠正为对称关系（即在该子数据集上不对称现象更轻、数据质量更好）时，它获得更大的权重，从而在式（6）的加权打分和式（9）的加权聚合中贡献更大。由此，权重与“不对称关系严重程度”呈反向关联——严重程度越低（对称比率越高），权重越大；又由定理 1，对称比率越高其骨架精度越高，故权重与子数据集所学结构的准确性呈单调正向映射。这一机制保证了高质量子数据集主导最终结果，低质量子数据集被自动抑制。

定理 2 记Q_c^*为算法 1 执行完第c批重采样后所保留的历史最优批次平均质量，即算法 1 第 7 行中的Q^*。若每批子数据集个数为L、步骤 1 识别出的不对称因果关系个数为K，则：（1）序列Q_c^*单调不减且以 1 为上界，因而收敛；（2）Q_c^*的取值落在含$KL+1$个元素的有限集$\{0, 1/(KL), 2/(KL), \dots, 1\}$中，故其严格增大至多发生$KL$次；（3）算法 1 必在有限批次内触发早停条件$e \ge T_{stop}$而终止，且所需批次数不超过$(KL+1)(T_{stop}+1)$。

证明 由式（4），$\psi_l^c(k) \in \{0,1\}$对一切k成立，故$Q(D_l^c)$是K个二值量的均值；再由式（7），$Q(\mathcal{D}^c)$是L个这样的均值的均值，即KL个二值量之和除以KL。因此$Q(\mathcal{D}^c)$只能取有限集$\{0, 1/(KL), 2/(KL), \dots, 1\}$中的值，该集合含$KL+1$个元素且包含于$[0,1]$。由算法 1 第 7 行的更新规则可知$Q_c^*$等于$Q_{c-1}^*$与$Q(\mathcal{D}^c)$之中的较大者，故$Q_c^*$单调不减；又其恒不超过 1，由单调有界收敛定理知该序列收敛，结论（1）成立。由于Q_c^*只在上述含$KL+1$个元素的有限集中取值，单调不减的序列在该集合上至多严格增大KL次，结论（2）成立。未提升计数e仅在$Q(\mathcal{D}^c)$超过Q^*时被清零，而这恰对应Q_c^*的一次严格增大，故清零至多发生$KL+1$次（含首批的一次赋值）。在两次相邻清零之间以及最后一次清零之后，e每批递增 1，故至多再经过T_{stop}批便有e不小于T_{stop}。于是算法 1 至多在$(KL+1)(T_{stop}+1)$批内终止，结论（3）成立。综上所述，定理 2 证毕。

定理 2 表明，早停并非人为截断，而是有确切的收敛与终止保证。实验中取$T_{stop}=3$：当批次平均质量的提升进入平台期后，继续重采样难以带来实质增益，连续未提升的次数即是对该平台的经验估计，该取值

在精度与计算开销之间取得了平衡。

关于高维稀疏场景下局部学习误差的传播路径及 ECSL 对此类误差的容忍限度：在局部到全局框架中，每个变量的因果邻居是通过条件独立性检验（或局部评分）独立学习得到的。在高维稀疏场景下，随着条件集规模增大而可用样本相对不足，条件独立性检验的统计功效下降，容易将真实依赖误判为独立（漏检因果邻居）或将虚假依赖误判为依赖（多检因果邻居）。这类局部误差的传播路径可归纳为：单个变量的因果邻居被误判→在对称性核对时表现为不对称因果关系→在拼接全局骨架时造成因果边的缺失或冗余→在后续定向阶段沿变量间的依赖路径进一步放大为级联错误。可见，局部学习误差正是通过“不对称因果关系”这一中间环节渗透进全局结构的，这也是 ECSL 选择以消除不对称关系为切入点的根本原因。ECSL 对此类误差的容忍机制体现在：它不依赖任何单次局部学习结果，而是在多批高质量子数据集上对存在不对称关系的变量对反复重新学习，并按子数据集质量进行加权投票（式（6））。因此，只要某一对变量的正确（对称）关系能够在占据多数权重的高质量子数据集上被恢复，相应的局部误差即可被纠正。据此可以刻画 ECSL 的容忍限度：当某处局部误差仅偶发于少数低质量子数据集时，ECSL 几乎总能将其纠正；当误差随稀疏程度加剧而系统性地出现在超过半数（按质量加权）的子数据集上时，加权投票不再占优，ECSL 对该误差的纠正能力随之下降；特别地，若某对变量在几乎所有子数据集上都被一致地错判为对称（即误差本身不表现为不对称），则超出了本文以对称比率为核心的纠正机制的适用范围，需借助功效更强的检验或引入先验知识加以解决。总体而言，ECSL 并不能消除任意强度的局部误差，但通过重采样集成与质量加权，显著提升了对随机扰动以及中等程度稀疏噪声所引发误差的容忍度。

3.3 全局骨架构建与定向

在上一节中，设计了一种新颖的策略去纠正 ECSL 在步骤 1 中产生的K个不对称因果关系。本节将首先利用 ECSL 在步骤 2 中纠正后的因果关系去构建全局因果骨架$\mathcal{S}$。具体来说，对于任意两个变量X_i和X_j，使用以下四条准则构建全局因果骨架：

(1) 在原始数据集D_{orig}上，如果发现X_i和X_j互为彼此因果邻居，则在全局因果骨架中将X_i和X_j相连，形成一条无向边。

(2) 如果X_i和X_j互不为彼此因果邻居，则在全局因果骨架中将不会有无向边连接X_i和X_j。

(3) 当X_i和X_j之间的因果关系不对称，但它们在最优一批子数据集$\mathcal{D}^C$上的集成总得分大于 0 时，将在全局因果骨架中连接X_i和X_j形成一条无向边。

(4) 当X_i和X_j之间的因果关系不对称，但它们在最优一批子数据集$\mathcal{D}^C$上的集成总得分小于等于 0 时，在全局因果骨架中将不会有无向边连接X_i和X_j。

上述四条准则可以形式化地表示为：

$$\mathcal{S}(i,j)=\begin{cases}1, X_j\in CN(X_i)\wedge X_i\in CN(X_j),\\ 0, X_j\notin CN(X_i)\wedge X_i\notin CN(X_j),\\ 1, \exists k\ \ s.t.\left(\left(X_i=R_a^k\wedge X_j=R_b^k\right)\vee\left(X_i=R_b^k\wedge X_j=R_a^k\right)\right)\wedge\widehat{Score}(R_a^k,R_b^k,C)>0,\\ 0, \exists k\ \ s.t.\left(\left(X_i=R_a^k\wedge X_j=R_b^k\right)\vee\left(X_i=R_b^k\wedge X_j=R_a^k\right)\right)\wedge\widehat{Score}(R_a^k,R_b^k,C)\leqslant 0,\end{cases} \tag{8}$$

其中$i=1,2,\ldots,m; j=1,2,\ldots,(i-1)$，且$\mathcal{S}(i,j)=\mathcal{S}(j,i)=1$表示在全局因果骨架中变量$X_i$和$X_j$之间存在一条无向边相连，而$\mathcal{S}(i,j)=\mathcal{S}(j,i)=0$表示它们之间不存在无向边相连。

由于原始数据集D_{orig}存在质量问题，本文没有直接在D_{orig}上应用重构后的全局因果骨架$\mathcal{S}$进行定向，而是选择了一个更精细的方法：将$\mathcal{S}$分别应用于最优一批子数据集$\{D_l^C\}_{l\in\{1,2,\ldots,L\}}$中的每个子数据集，以进行定向。在本文中，利用爬山搜索策略结合 BDeu 评分[42]在每个子数据集上贪婪地定向$\mathcal{S}$中所有无向因果边。令$\mathcal{G}_l^C$表示在最优一批子数据集中第l个子数据集上学到的因果结构。

关于在消除不对称关系后的骨架上采用爬山搜索结合 BDeu 评分进行定向的适用性说明：经过步骤 2 的纠正，全局骨架已尽可能接近真实骨架，无向边的

数量与位置得到有效约束，这使得后续定向的搜索空间被大幅压缩到一个规模更小、条件更良好的解空间内，既降低了爬山搜索陷入较差局部最优的风险，也提升了效率。BDeu 是针对离散多项分布贝叶斯网络的评分标准，具有评分等价性与大样本一致性，与本文基准数据（离散贝叶斯网络）的分布假设相匹配；而爬山搜索作为一种成熟的贪婪局部搜索策略，在受纠正骨架约束的前提下能够高效地确定边的方向。此外，本文并非在单一数据集上一次性定向，而是在最优批次的多个子数据集上分别定向并加权聚合（式（9）和（10）），进一步抑制了单次贪婪搜索可能引入的定向误差。消融实验（表 2）中 ECSL 相对各变体的稳定提升也从实验角度支撑了该定向策略在纠正后骨架上的有效性。

通过交替执行爬山搜索过程和 BDeu 评分标准，ECSL 在每个子数据集上获得了得分最高的全局因果结构。令$\mathcal{G}_l^C(i,j)=1$（邻接矩阵）表示在$\mathcal{G}_l^C$中有一条从变量X_i指向变量X_j的有向因果边，而$\mathcal{G}_l^C(i,j)=0$（邻接矩阵）表示在$\mathcal{G}_l^C$中不存在从X_i指向X_j的有向因果边。根据公式（4），$\mathcal{D}^C=\{D_1^C,D_2^C,\dots,D_L^C\}$中每个子数据集的质量不同，因此在聚合每个子数据集上得到的因果结构$\{\mathcal{G}_l^C\}_{l\in\{1,2,\dots,L\}}$时采用如下的加权聚合策略。

$$\mathcal{G}^*=\left(\mathcal{G}_1^C*Q(D_1^C)\right)\oplus\left(\mathcal{G}_2^C*Q(D_2^C)\right)\oplus\cdots\oplus\left(\mathcal{G}_L^C*Q(D_L^C)\right),\quad(9)$$

其中⊕表示矩阵的逐元素加法。最后，比较邻接矩阵$\mathcal{G}^*$中斜对角线上对应位置元素大小以获取最终的全局因果结构。如果$\mathcal{G}^*(i,j)>\mathcal{G}^*(j,i)$，则构建一条从变量$X_i$指向变量$X_j$的有向因果边；如果$\mathcal{G}^*(i,j)\le\mathcal{G}^*(j,i)$且$\mathcal{G}^*(j,i)\neq 0$，则构建一条从$X_j$指向$X_i$的有向因果边；否则，$X_i$和$X_j$之间无因果边相连。上述的判定流程可以形式化为：

$$\begin{cases}X_i\to X_j, & \mathcal{G}^*(i,j)>\mathcal{G}^*(j,i),\\ X_i\leftarrow X_j, & \mathcal{G}^*(i,j)\leqslant\mathcal{G}^*(j,i)\wedge\mathcal{G}^*(j,i)\neq 0,\\ X_i\nleftrightarrow X_j, & \mathcal{G}^*(i,j)=0\wedge\mathcal{G}^*(j,i)=0,\end{cases}\quad(10)$$

其中$i=1,2,\dots,m;j=1,2,\dots,(i-1)$。

4 实验结果及分析

本节通过在基准数据集和真实数据集上进行实验来评估所提算法的有效性，并进行消融实验来进一步验证本文所设计的策略的有效性。

4.1 实验设置

4.1.1 对比算法

将本文提出的 ECSL 算法与三种具有代表性的局部到全局因果结构学习算法进行比较，包括 GSBN[27]、F2SL-c[30]、F2SL-s[30]，以及五种最先进的全局因果结构学习算法，包括 GES[19]、PC-stable[16]、NOTEARS[22]、DAG-GNN[23]和 GOLEM[24]，以及近两年提出的两种先进因果结构学习算法 ReX[41]和 DCILP[43]。

4.1.2 评价指标

本文采用了两种常用的评估指标：结构汉明距离（structural Hamming distance，SHD）和 F1 分数（F1 score），以评估所有算法学习到的因果结构的准确性。其中，SHD 指的是学到因果结构中错误边的总数，包括定向错误的边、缺失的边和多余的边。

与 SHD 指标相比，F1 score 不仅考虑学习错误的边而且考虑学习正确的边，且 F1 score 的值越大表示学到的因果结构越准确。在所有的图表中，（↑）表示数值越高越好，而（↓）表示数值越低越好。

4.1.3 数据集

为了验证算法的有效性，本文选取了如下两种类型数据集。

(1) 基准数据集：在 12 个基准贝叶斯网络数据集[42]上进行实验。每个贝叶斯网络都生成三批数据集，分别包含 500、1,000 和 5,000 个数据样本。这些基准贝叶斯网络的详细信息见表 1。

表 1 12 个基准贝叶斯网络信息

Table 1 Information of 12 benchmark Bayesian networks

网络名称	节点个数	边个数	最大入度	最大出度	最大邻居数	网络规模
Child	20	25	2	7	8	小型
Child3	60	79	3	7	8	中型
Child5	100	126	2	7	8	大型
Child10	200	257	2	7	8	超大型
Insurance	27	52	3	7	9	小型
Insurance3	81	163	4	7	9	中型
Insurance5	135	281	5	8	10	大型
Insurance10	270	556	5	8	11	超大型
Alarm	37	46	4	5	6	小型
Alarm3	111	149	4	5	6	大型
Alarm5	185	265	4	6	8	大型
Alarm10	370	570	4	7	9	超大型

(2) 真实数据集：将提出的方法与基线方法在Sachs[7]生物数据集上进行比较。Sachs 是一个代表人类细胞中蛋白质信号网络的基准图模型，它包含 11 个节点（细胞类型）和 17 条边。实验使用了包含 7,466 个样本的观测数据。

4.2 基准数据集实验

在图 3 和图 4 所示的结果中，可以观察到，无论是采用 F1 score 评价指标还是采用 SHD 评价指标，本文提出的 ECSL 算法在大部分数据集上均优于对比的算法。并且，随着样本数量的增加，ECSL 的优势更为显著。基于连续优化的因果结构学习算法，例如 NOTEARS、DAG-GNN 和 GOLEM，在基准贝叶斯网络数据集上表现不佳，这可能归因于它们更适用于处理连续数据而非离散数据，使得这些算法能够更快地达到收敛，实现损失函数值的最小化。

从实验结果的整体趋势来看，局部到全局的因果结构学习算法在大多数基准数据集上的表现普遍优于传统的全局因果结构学习算法。这一现象并非偶然，而是反映了两类方法在学习范式上的根本差异。全局方法通常以整体优化的方式同时估计所有变量之间的因果关系，其学习过程高度耦合：一旦某些变量的局部结构出现误判，错误便会沿着变量之间的依赖路径在搜索空间中不断扩散，进而引发“级联错误”现象，使得最终输出的全局因果图在精度和稳定性方面均受到显著影响。相比之下，局部到全局的方法采取“分而治之”的策略，先以每个变量为中心独立地学习其局部因果邻居（如父节点、子节点及配偶节点），再通过合并各局部结构构造出完整的全局因果图。由于每个变量的局部学习过程在很大程度上彼此独立，单一变量上的误判被有效地隔离在其邻域之内，难以扩散并污染其他变量的学习结果，从而在整体上提升了全局因果结构的准确性与鲁棒性。

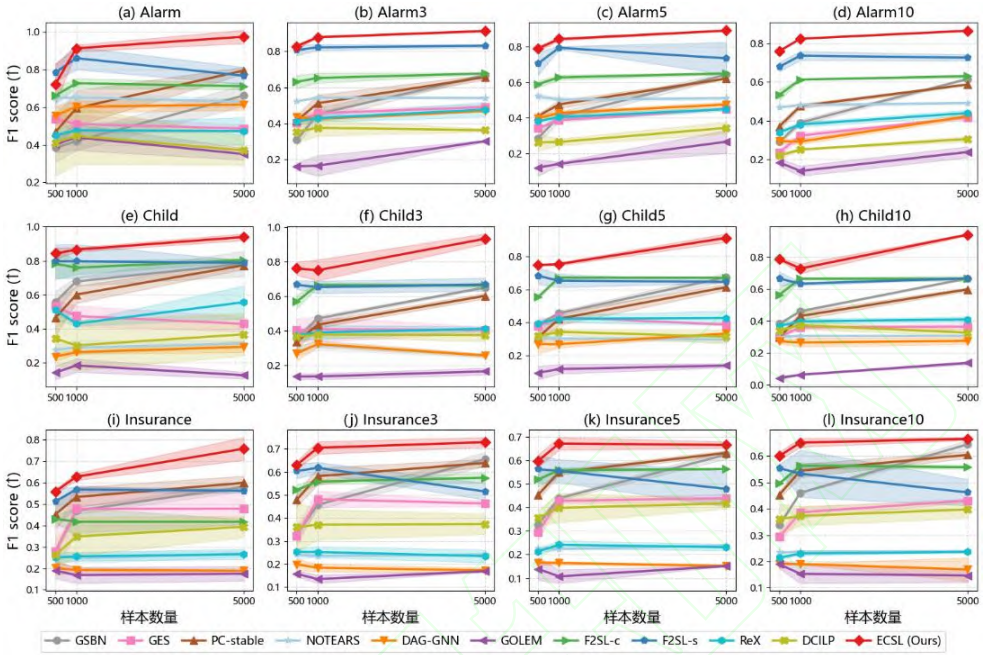


图 3　ECSL 和其竞争对手在所有基准数据集上的 F1 score（含 500、1,000 和 5,000 个样本）

Fig.3　F1 scores of ECSL and its rivals on all benchmark datasets with 500, 1,000 and 5,000 samples

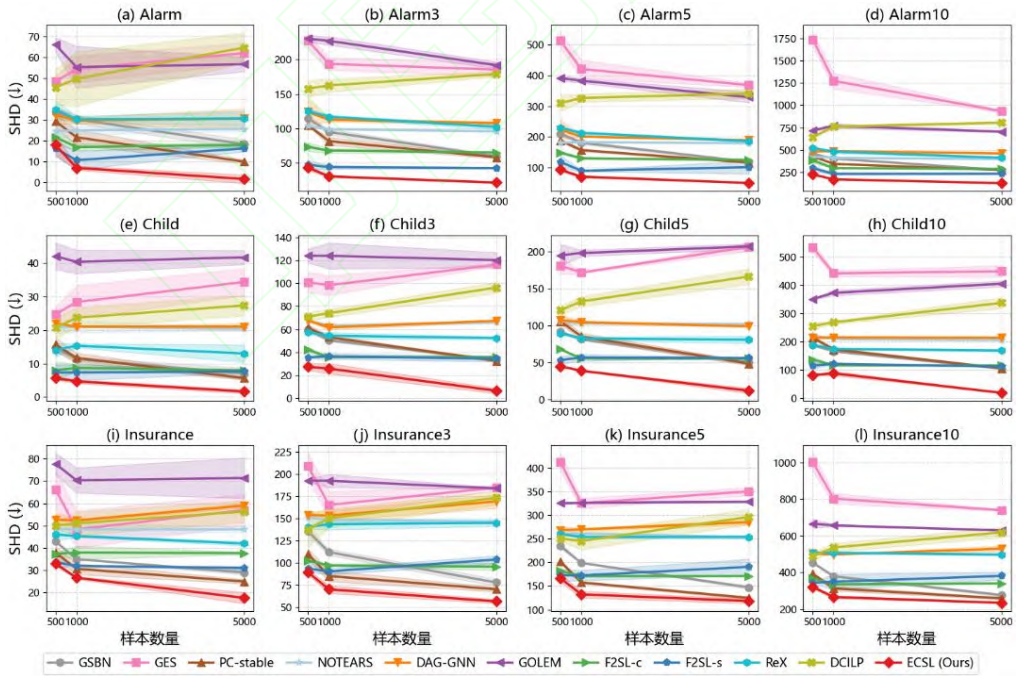


图 4　ECSL 和其竞争对手在所有基准数据集上的 SHD（含 500、1,000 和 5,000 个样本）

Fig.4　SHDs of ECSL and its rivals on all benchmark datasets with 500, 1,000 and 5,000 samples

尽管局部到全局类方法在已有研究中已经展现出令人瞩目的性能，但其自身仍存在若干尚未充分解决的固有缺陷，其中最为突出的便是因果关系的不对称性问题。针对上述瓶颈，本文所提出的 ECSL 算法在传统局部到全局框架的基础上实现了显著的性能跃升，其核心贡献在于将数据重采样与集成学习的思想

有机融合，并据此设计了一种针对性的不对称因果关系纠正机制。一方面，通过对原始数据进行多次重采样，ECSL 能够在不同的数据子集上重复执行局部因果结构学习过程，从而获得对同一因果关系的多个独立估计，有效缓解了单次学习过程中由数据偏差所引起的随机误差；另一方面，集成学习的引入使得算法能够对来自不同视角、不同采样下的判断结果进行加权融合与一致性校验，从而在统计意义上甄别并修正那些表现为“不对称”的可疑因果关系。

此外，本文进一步引入近两年提出的 ReX[41]和 DCILP[43]两种先进算法作为对比基线。实验结果显示，二者在离散的基准贝叶斯网络数据上整体表现欠佳：ReX 基于回归模型与 Shapley 值进行因果发现，DCILP 则依赖高斯线性结构方程模型来估计马尔可夫毯，二者的建模假设更契合连续（尤其是线性高斯）数据，因而在离散多值的贝叶斯网络数据上难以充分发挥优势。以 Alarm 数据集 5000 样本为例，ECSL 的 F1 分数达到 0.974，而 ReX 与 DCILP 分别仅为 0.472 和 0.369；在全部 12 个基准网络上，ECSL 的 F1 分数与 SHD 指标均显著优于 ReX 和 DCILP，且随着样本量增加优势愈发明显。这表明，针对离散贝叶斯网络数据，面向不对称因果关系消除的局部到全局框架相比新近的连续型/可解释性方法具有明显优势。

4.3 真实数据集实验

图 5 展示了在真实的 Sachs 数据集上，ECSL 算法与其它竞争方法的实验结果对比。可以清晰地看到，ECSL 不仅取得了最高的 F1 score，也实现了最低的 SHD 值。在新增的两种对比算法中，ReX 凭借其面向连续数据的建模能力，在 Sachs 数据上取得了仅次于 ECSL 的 F1 分数（0.462）与较低的 SHD（12），而 DCILP 的表现相对一般（F1 为 0.353，SHD 为 29）。即便如此，ECSL 仍以最高的 F1 分数（0.552）和最低的 SHD（10）取得最佳结果。这进一步印证了：真实数据中同样普遍存在不对称因果关系，本文提出的不对称因果关系纠正策略在真实数据上依然有效。

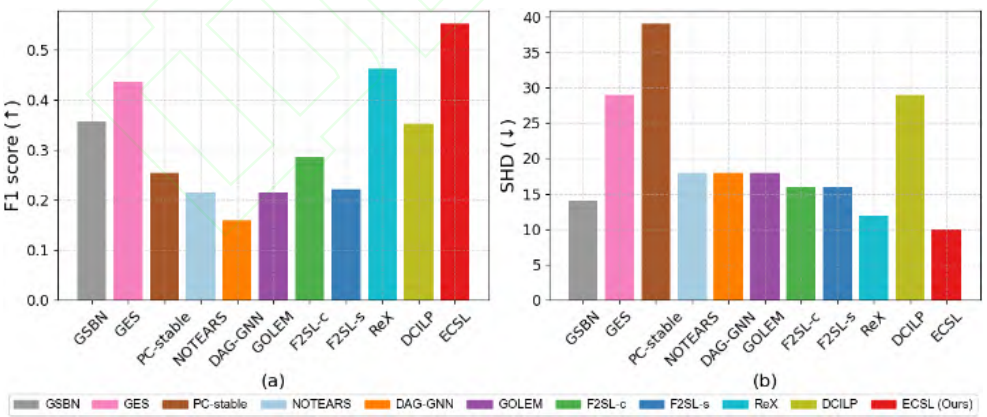


图 5　在真实的 Sachs 数据集上的实验结果

Fig.5　Experimental results on the real Sachs dataset

4.4 消融实验

为了验证本文提出的子数据集质量评估策略以及迭代重采样策略的有效性，设计了两个变体算法。第一个变体算法忽略了重采样后各子数据集质量的差异性，即在加权聚合的所有阶段中赋予每个子数据集相同的权重，将这个算法命名为 ECSL-Simple-I。第二个变体算法在 ECSL 的步骤 2 中放弃了迭代式重采样以选择最优一批子数据集的做法，而是直接使用第一批重采样的子数据集来进行不对称因果关系的纠正，将这个算法命名为 ECSL-Simple-II。在三个基准数据

集上对这两个简化算法及本文提出的 ECSL 算法进行了对比实验，结果如表 2 所示。根据表 2 展示的结果，可以明显看出：本文提出的 ECSL 算法性能超越了 ECSL-Simple-I和 ECSL-Simple-II，这证明了在因果结构学习中，区分不同子数据集的质量进行加权聚合，并且采用迭代重采样方法来选取最优一批子数据集的策略，是确实有效的。

表 2 消融实验结果

Table 2 Results of ablation experiments

评价指标	数据集	ECSL-Simple-I	ECSL-Simple-II	ECSL (Ours)
F1 score (↑)	Child	0.846±0.083	0.837±0.065	**0.865±0.013**
	Insurance	0.616±0.012	0.618±0.030	**0.626±0.017**
	Alarm	0.908±0.010	0.874±0.083	**0.912±0.018**
SHD (↓)	Child	5.333±2.309	5.333±1.528	**4.667±0.577**
	Insurance	27.333±0.577	27.333±1.528	**26.667±0.577**
	Alarm	8.000±1.000	9.000±4.583	**7.000±1.000**

针对算法对异常样本、异质性、稀疏性及非高斯噪声等的鲁棒性，进一步分析如下。(1) 异常样本与噪声：ECSL 通过自助法生成多批次子数据集，并以对称比率作为质量度量进行加权聚合，含异常/噪声较多的低质量子数据集会被自动赋予较低权重甚至被淘汰，从而降低异常样本对最终结构的影响，这与消融实验中“区分子数据集质量的加权聚合优于等权聚合”的结论一致。(2) 异质性：多批次重采样在样本层面引入了多样性，加权聚合相当于对来自不同数据子集的多个估计进行一致性融合，有助于缓解数据局部异质性带来的偏差。(3) 小样本与稀疏性：ECSL 以各变量的局部因果邻居学习为基础，其计算规模主要取决于邻居集大小而非全体变量数，适合稀疏因果结构；实验中 ECSL 在 500 小样本下相对基线已具明显优势，体现了对小样本的适应性。(4) 非高斯噪声：ECSL 面向离散贝叶斯网络数据，采用基于条件独立/评分的因果邻居学习与 BDeu 定向，不依赖高斯或线性假设，因而不受非高斯噪声假设的限制；相比之下，NOTEARS、GOLEM 及新增的 DCILP 等方法多建立在（线性）高斯假设之上，在离散非高斯数据上的表现明显受限。

综合来看，ECSL 在 12 个不同规模与稠密度的基准网络上均取得稳定且领先的结果，且各指标的标准差普遍较小，从实验角度佐证了算法对样本扰动、网络规模变化与数据质量差异具有较好的鲁棒性。对连续数据、混合数据及显式的异质性场景的自适应处理，将作为未来工作的重点方向。

5 结束语

本文提出了一种基于不对称因果关系消除的因果结构学习算法 ECSL。与现有局部到全局的因果结构学习方法相比，ECSL 通过自助法生成多批次高质量的子数据集，利用因果邻居修正每批次数据上学到的局部因果结构，消除了不对称因果关系的影响，并通过加权聚合策略获得了鲁棒的全局因果结构。在基准数据集和真实数据集上的实验表明，ECSL 在因果结构学习的准确性方面优于现有主流算法。未来工作主要包括以下几个方面：第一，扩展 ECSL 以处理更复杂的数据类型，如连续变量和混合变量；第二，将 ECSL 与深度学习模型相结合，以处理变量之间非线性因果关系；第三，探索 ECSL 在实际应用中的可解释性，如医疗诊断、金融风险评估等。

需要特别指出的是，当前 ECSL 主要面向离散型

贝叶斯网络数据，将其推广到连续变量或混合数据类型仍面临若干适配障碍。首先，在因果邻居学习环节，ECSL 依赖适用于离散数据的条件独立性检验（如G^2检验、χ^2检验）；面向连续数据时通常需改用 Fisher-Z 检验（隐含线性高斯假设），或改用基于核的条件独立性检验（kernel-based conditional independence，KCI）、希尔伯特-施密特独立性准则（Hilbert-Schmidt independence criterion，HSIC）等核方法，但后者计算开销较大；而混合数据还需要能够同时处理离散与连续变量的专门检验，检验方式的改变会直接影响因果邻居乃至不对称关系识别的准确性。其次，在骨架定向环节，本文采用面向离散多项分布的 BDeu 评分，连续数据一般需替换为贝叶斯高斯等价（Bayesian Gaussian equivalent，BGe）评分，混合数据则需条件高斯等评分函数，否则难以保证评分等价性与一致性。再次，ECSL 以因果邻居对称比率作为子数据集质量度量，该度量本身与数据类型无关，但其可靠性取决于底层独立性检验的功效，在连续/混合场景下同样会受到检验选择的影响。值得强调的是，ECSL“局部到全局 + 重采样集成 + 质量加权”的整体框架与具体数据类型并不耦合，主要的适配工作集中于替换因果邻居学习与骨架定向两个模块。因此，未来可通过引入核条件独立性检验、秩相关或 Copula 等非参数方法来处理连续与混合数据，并结合 BGe、条件高斯等评分函数完成定向，从而将 ECSL 拓展为适用于更广泛数据类型的通用框架。

参考文献：

[1] 蔡瑞初, 陈薇, 张坤, 等. 基于非时序观察数据的因果关系发现综述[J]. 计算机学报, 2017, 40(7): 1470-1490.
CAI R, CHEN W, ZHANG K, et al. A survey on non-temporal series observational data based causal discovery[J]. Chinese Journal of Computers, 2017, 40(7): 1470-1490.

[2] KUANG K, LI L, GENG Z, et al. Causal inference[J]. Engineering, 2020, 6(3): 253-263.

[3] CHEN W, CAI R, ZHANG K, et al. Causal discovery in linear non-Gaussian acyclic model with multiple latent confounders[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 33(7): 2816-2827.

[4] 杨帅, 王浩, 俞奎, 等. 基于实例加权和双分类器的稳定学习算法[J]. 软件学报, 2023, 34(7): 3206-3225.
YANG S, WANG H, YU K, et al. Stable learning via sample reweighting and dual classifiers[J]. Journal of Software, 2023, 34(7): 3206-3225.

[5] 梁吉业, 钱宇华, 李德玉, 等. 大数据挖掘的粒计算理论与方法[J]. 中国科学: 信息科学, 2015, 45(11): 1355-1369.
LIANG J Y, QIAN Y H, LI D Y, et al. Theory and method of granular computing for big data mining[J]. Scientia Sinica Informationis, 2015, 45(11): 1355-1369.

[6] XIAO L, WU X, XU J, et al. Atlantis: aesthetic-oriented multiple granularities fusion network for joint multimodal aspect-based sentiment analysis[J]. Information Fusion, 2024, 106: 102304.

[7] SACHS K, PEREZ O, PE'ER D, et al. Causal protein-signaling networks derived from multiparameter single-cell data[J]. Science, 2005, 308(5721): 523-529.

[8] RICHENS J G, LEE C M, JOHRI S. Improving the accuracy of medical diagnosis with causal machine learning[J]. Nature Communications, 2020, 11: 3923.

[9] QIAO J, CAI R, ZHANG K, et al. Causal discovery with confounding cascade nonlinear additive noise models[J]. ACM Transactions on Intelligent Systems and Technology, 2021, 12(6): 1-28.

[10] HE Y, CUI P, SHEN Z, et al. Daring: differentiable causal discovery with residual independence[C]//Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining. New York: ACM, 2021: 596-605.

[11] CAI R, HUANG Z, CHEN W, et al. Causal discovery with latent confounders based on higher-order cumulants[C]//Proceedings

of the 40th International Conference on Machine Learning. Honolulu: PMLR, 2023: 3380-3407.

[12] KUANG K, WANG H, LIU Y, et al. Stable prediction with leveraging seed variable[J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 35(6): 6392-6404.

[13] VOWELS M J, CAMGOZ N C, BOWDEN R. D'ya like DAGs? a survey on structure learning and causal discovery[J]. ACM Computing Surveys, 2022, 55(4): 1-36.

[14] ZANGA A, OZKIRIMLI E, STELLA F. A survey on causal discovery: theory and practice[J]. International Journal of Approximate Reasoning, 2022, 151: 101-129.

[15] SPIRTES P, GLYMOUR C. An algorithm for fast recovery of sparse causal graphs[J]. Social Science Computer Review, 1991, 9(1): 62-72.

[16] COLOMBO D, MAATHUIS M H. Order-independent constraint-based causal structure learning[J]. Journal of Machine Learning Research, 2014, 15(1): 3741-3782.

[17] LI H, CABELI V, SELLA N, et al. Constraint-based causal structure learning with consistent separating sets[C]//Proceedings of the 33rd International Conference on Neural Information Processing Systems. Vancouver: NIPS Foundation, 2019: 14257-14266.

[18] SONDHI A, SHOJAIE A. The reduced PC-algorithm: improved causal structure learning in large random networks[J]. Journal of Machine Learning Research, 2019, 20(1): 1-31.

[19] CHICKERING D M. Optimal structure identification with greedy search[J]. Journal of Machine Learning Research, 2002, 3: 507-554.

[20] RAMSEY J, GLYMOUR M, SANCHEZ-ROMERO R, et al. A million variables and more: the fast greedy equivalence search algorithm for learning high-dimensional graphical causal models, with an application to functional magnetic resonance images[J]. International Journal of Data Science and Analytics, 2017, 3(2): 121-129.

[21] CHICKERING M. Statistically efficient greedy equivalence search[C]//Proceedings of the 36th Conference on Uncertainty in Artificial Intelligence. Virtual Online: PMLR, 2020: 241-249.

[22] ZHENG X, ARAGAM B, RAVIKUMAR P, et al. DAGs with NO TEARS: continuous optimization for structure learning[C]//Proceedings of the 32nd International Conference on Neural Information Processing Systems. Montréal: NIPS Foundation, 2018: 9492-9503.

[23] YU Y, CHEN J, GAO T, et al. DAG-GNN: DAG structure learning with graph neural networks[C]//Proceedings of the 36th International Conference on Machine Learning. California: PMLR, 2019: 7154-7163.

[24] NG I, GHASSAMI A E, ZHANG K. On the role of sparsity and DAG constraints for learning linear DAGs[C]//Proceedings of the 34th International Conference on Neural Information Processing Systems. Virtual Online: NIPS Foundation, 2020: 17943-17954.

[25] NG I, ZHU S, FANG Z, et al. Masked gradient-based causal structure learning[C]//Proceedings of the 2022 SIAM International Conference on Data Mining. Alexandria: SIAM, 2022: 424-432.

[26] CHICKERING M, HECKERMAN D, MEEK C. Large-sample learning of Bayesian networks is NP-hard[J]. Journal of Machine Learning Research, 2004, 5: 1287-1330.

[27] MARGARITIS D, THRUN S. Bayesian network induction via local neighborhoods[C]//Proceedings of the 12th International Conference on Neural Information Processing Systems. Colorado: MIT Press, 1999: 505-511.

[28] NIINIMÄKI T, PARVIAINEN P. Local structure discovery in Bayesian networks[C]//Proceedings of the 28th Conference on Uncertainty in Artificial Intelligence. Catalina Island: AUAI Press, 2012: 634-643.

[29] GAO T, FADNIS K, CAMPBELL M. Local-to-global Bayesian network structure learning[C]//Proceedings of the 34th International Conference on Machine Learning. Sydney: PMLR, 2017: 1193-1202.

[30] YU K, LING Z, LIU L, et al. Feature selection for efficient local-to-global Bayesian network structure learning[J]. ACM Transactions on Knowledge Discovery from Data, 2023, 18(1): 1-27.

[31] GUO X, YU K, LIU L, et al. Adaptive skeleton construction for accurate DAG learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 35(10): 10526-10539.

[32] GUO X, YU K, LIU L, et al. Progressive skeleton learning for effective local-to-global causal structure learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(12): 9065-9079.

[33] YU K, GUO X, LIU L, et al. Causality-based feature selection: methods and evaluations[J]. ACM Computing Surveys, 2020, 53(5): 1-36.

[34] MEEK C. Causal inference and causal explanation with background knowledge[C]//Proceedings of the 11th Conference on Uncertainty in Artificial Intelligence. Montreal: Morgan Kaufmann, 1995: 403-410.

[35] HUANG B, ZHANG K, LIN Y, et al. Generalized score functions for causal discovery[C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. London: ACM, 2018: 1551-1560.

[36] ALIFERIS C F, TSAMARDINOS I, STATNIKOV A. HITON: a novel Markov blanket algorithm for optimal variable selection[C]//Proceedings of the American Medical Informatics Association. Washington: AMIA, 2003: 21-25.

[37] RODRIGUES DE MORAIS S, AUSSEM A. A novel scalable and data efficient feature subset selection algorithm[C]//Proceedings of the Joint European Conference on Machine Learning and Knowledge Discovery in Databases. Berlin: Springer, 2008: 298-312.

[38] TSAMARDINOS I, ALIFERIS C F, STATNIKOV A. Time and sample efficient discovery of Markov blankets and direct causal relations[C]//Proceedings of the 9th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. Washington: ACM, 2003: 673-678.

[39] LI J, LIU L, LE T D, et al. Local causal discovery with a simple PC algorithm[J]. Practical Approaches to Causal Relationship Exploration, 2015, 1: 9-21.

[40] DE CAMPOS C P, SCANAGATTA M, CORANI G, et al. Entropy-based pruning for learning Bayesian networks using BIC[J]. Artificial Intelligence, 2018, 260: 42-50.

[41] RENERO J, MAESTRE R, OCHOA I. ReX: causal discovery based on machine learning and explainability techniques[J]. Pattern Recognition, 2026, 172: 112491.

[42] TSAMARDINOS I, BROWN L E, ALIFERIS C F. The max-min hill-climbing Bayesian network structure learning algorithm[J]. Machine Learning, 2006, 65(1): 31-78.

[43] DONG S, SEBAG M, UEMURA K, et al. DCILP: a distributed approach for large-scale causal structure learning[C]//Proceedings of the 39th AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2025: 16345-16353.

[44] PEARL J. Graphs, causality, and structural equation models[J]. Sociological Methods & Research, 1998, 27(2): 226-284.

[45] HESTERBERG T. Bootstrap[J]. Wiley Interdisciplinary Reviews: Computational Statistics, 2011, 3(6): 497-526.



郭贤杰（1996—），男，博士，副教授，主要研究方向为可信人工智能、数据挖掘、因果发现、联邦学习等。CCF 会员

GUO Xianjie, born in 1996, Ph.D., associate professor. His research interests include trustworthy artificial intelligence, data mining, causal discovery, federated learning, etc.



周浩（1993—），男，博士，副教授，主要研究方向为隐私保护、边缘计算等。CCF 会员

ZHOU Hao, born in 1993, Ph.D., associate professor. His research interests include privacy preservation, edge computing, etc.



俞奎（1977—），男，博士，教授，主要研究方向为数据挖掘、因果推断等。CCF 会员

YU Kui, born in 1977, Ph.D., professor, Ph.D. supervisor. His research interests include data mining, causal inference, etc.